Inhaltsübersicht

1. Einleitung und thematische Annäherung
2. Grundlagen, Grundkonzepte und Architektur von Datenbanksystemen
3. Konzeptioneller (fachlicher) Datenbank-Entwurf und das Entity-Relationship-Modell
4. Das relationale Datenmodell
5. SQL
6. Relationaler Schemaentwurf
7. Datenbank-Transaktionen und Transaktionsverwaltung
8. Physische Datenbank-Organisation
9. Ausblick auf weiterführende DBS-bezogene Themen

Physische Datenspeicherung und Datenorganisation von DBen

- **Bisher wurden in erster Linie Datenbank(system)-Konzepte und die logische Sicht auf Datenbanken betrachtet.**

- **Datenbanken werden physisch als Dateien auf einem Sekundärspeichermedium (Festplatte) gespeichert (oft eine Datei pro Tabelle).**

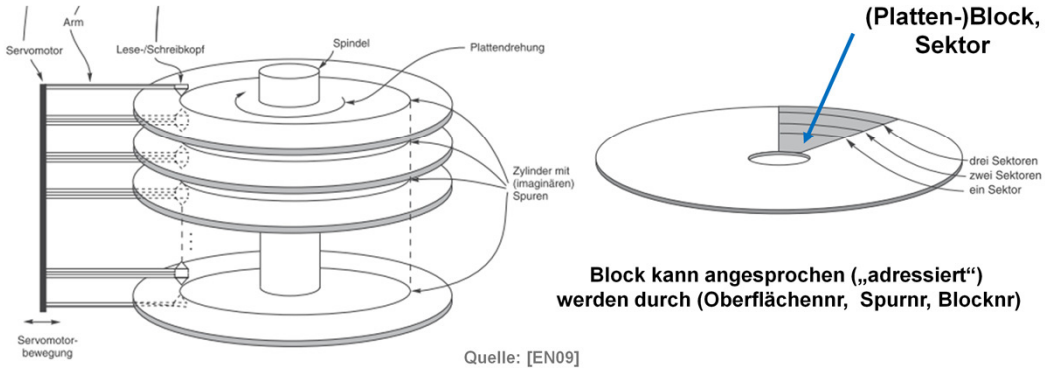

Block kann angesprochen („adressiert") werden durch (Oberflächennr, Spurnr, Blocknr)

Quelle: [EN09]

- **Eine Datei einer Datenbank untergliedert sich in Datensätze (= „physisches Abbild" eines Tupels), die jeweils aus einzelnen Datenwerten (= „physisches Abbild" eines Attributwerts) bestehen**

- Primärspeicher (auch als „interner Speicher" bezeichnet): Hauptspeicher / Arbeitsspeicher eines Rechnersystems, auch Cache-Speicher.
  Auf Primärspeicher kann vom Prozessor (CPU – Central Processing Unit) des Rechners direkt zugegriffen werden.

- Sekundärspeicher (auch als „externer Speicher" oder „peripherer Speicher" bezeichnet): Festplatten, optische Platten oder früher auch Magnetbänder.
  Kein direkter Zugriff durch Prozessor, Daten von Sekundärspeicher müssen zunächst in den Primärspeicher kopiert werden.

- Ablaufende Programme (wie z.B. das DBMS bzw. seine zentralen Komponenten) befinden sich als ausführbarer Code im Hauptspeicher.

- Datenbanken liegen aufgrund ihrer Größe üblicherweise auf Sekundärspeichermedien. Teile der Datenbank werden nach Bedarf in den Hauptspeicher geladen und dort vom DBMS verarbeitet.

- Im Allgemeinen sind Datenbanken auch heute meist noch zu groß um komplett in den Hauptspeicher geladen zu werden.

Physische Datenspeicherung und Datenorganisation von DBen

- **Das DBMS muss zur Abarbeitung von Anfragen und Operationen Datensätze vom Sekundärspeicher lesen (lassen).**
  (Ausnahme: Die benötigten Daten sind bereits im Arbeitsspeicher vorhanden bzw. gepuffert)

  - **Das DBMS bzw. Datenbankanwendungen benötigen für die Abarbeitung von Operationen oft nur einen (kleinen?) Teil der Datenbank**
  - **Dieser wird bei Bedarf in den Hauptspeicher kopiert.**
  - **Im Fall von Änderungen werden die Daten wieder auf die Festplatte geschrieben**

- **Die Datensätze einer physischen Datei der Datenbank sind auf Blöcke verteilt**

- **Blöcke sind die Einheiten/Größen des Datentransfers zwischen Festplatte und Hauptspeicher (nicht einzelne Datensätze !)**

Physische Datenspeicherung und Datenorganisation von DBen: Speicherhierarchie moderner Rechnersysteme

Zugriff auf Blöcke auf der Platte ist „teuer“ (d.h. zeitaufwendig im Vergleich zur Arbeitsgeschwindigkeit des Prozessors bzw. zur Zugriffszeit auf den Hauptspeicher):

Zugriffszeit = Suchzeit (Armpositionierung)
+ Umdrehungsverzögerung
+ Blocktransferzeit

→ ***Millisekunden-Bereich (vgl. Unterschied zu Prozessortakt!)***

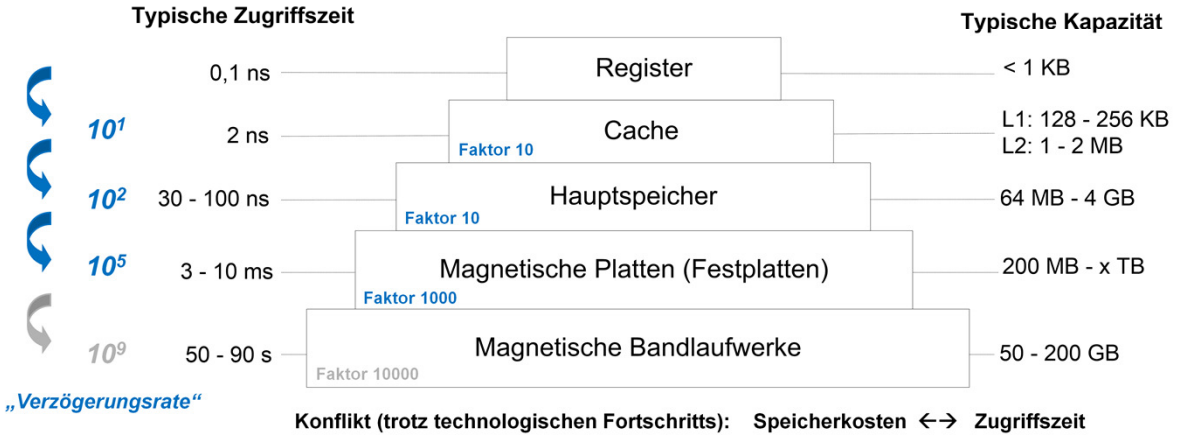

Konflikt (trotz technologischen Fortschritts): Speicherkosten ←→ Zugriffszeit

Physische Dateiorganisation

- Es gibt mehrere Möglichkeiten zur primären Dateiorganisation, d.h. zur physischen Anordnung der Datensätze in einer Datei (genauer: in den Blöcken der Datei).

- Die physische Anordnung der Datensätze in den Blöcken hat direkte Auswirkung auf die Anfrageabarbeitung:
  Unterstützung / Beschleunigung bestimmter Operationen
  (Einzelsatzanfrage, Bereichsanfrage, …)

- Grundlegende Formen der (primären) Dateiorganisation:

  - Heap-Datei (ungeordnete Datei)
    - Ablage neuer Datensätze auf der Platte „am Ende“ der Datei
    - Einfügen eines Datensatzes sehr effizient: Lese letzten Block der Datei, füge Satz ein, schreibe Block auf Platte zurück
    - Suche ist teuer: Lineare Suche – im Extremfall müssen alle Blöcke gelesen werden
    - Löschen erzeugt „Löcher“ im Block → Reorganisation nötig

Physische Dateiorganisation

- **Grundlegende Formen der (primären) Dateiorganisation (Fortsetzung):**

  - **Sortierte Datei (auch als sequentielle Datei bezeichnet)**
    - Ablage der Datensätze geordnet nach dem Wert eines bestimmten Feldes (Sortierkriterium bzw. „Sortierschlüssel“, wenn das Feld gleichzeitig Schlüssel ist)
    - Sehr effizientes Suchen möglich: Binäre Suche
    - Aber: Effizient nur bei Zugriff auf Datensätze anhand des Sortierkriteriums
    - Einfügen & Löschen: Teure Operation, da Ordnung hergestellt werden muss

  - **Hash-Datei**
    - Geeignet für bestimmte Suchbedingungen: Gleichheit auf einem Feld des Datensatzes. Dieses Feld wird als „Hash“-Feld bezeichnet.
    - Dazu wird eine math. Funktion (Hash-Funktion) auf den Wert des Hash-Feldes angewandt
    - Die Funktion liefert die Adresse des Blocks, in dem der Datensatz liegt
      → In der Regel nur ein Blockzugriff!

  - **Baumstrukturen (Suchbäume; B-Bäume; B*-Bäume): siehe später …**

Indexstrukturen

- Eine Datei kann physisch nur anhand <u>eines</u> Kriteriums geordnet sein

- Daher: Unterstützung <u>weiterer</u> Zugriffskriterien durch zusätzliche („sekundäre“) Zugriffsstrukturen: Indexe (vgl. auch Kapitel „SQL“)
  - Kann weitere Felder (d.h. andere „Suchkriterien“) zur Sortierung nutzen
  - Dadurch Beschleunigung von Zugriffen anhand anderer Suchkriterien, ohne die primäre Dateiorganisation zu ändern
  - Struktur eines Index nutzt meist sortierte Dateien oder Baumstrukturen
    (aber auch Hashing ist prinzipiell als Indexstruktur nutzbar)
  - Ansatz analog zur primären Dateiorganisation:
    Wähle Feld(er) als Indexfeld(er), Dateiorganisation erfolgt anhand der Felder
  - Index ist eine zusätzliche Datei
  - Blöcke der Indexdatei enthalten für jeden Datensatz der zugrundeliegenden Datei einen Eintrag mit 2 Feldern:
    - Wert des Indexfelds
    - Adresse des (Platten-)Blocks, in dem der Datensatz zu finden ist

Prinzip eines (Sekundär-)Index

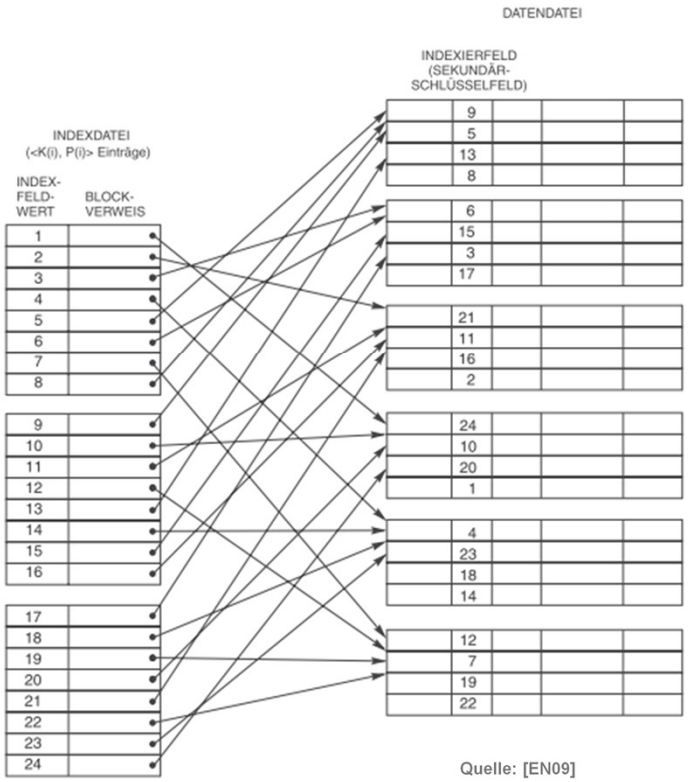

Quelle: [EN09]

Index auch für Primärschlüssel sinnvoll ...

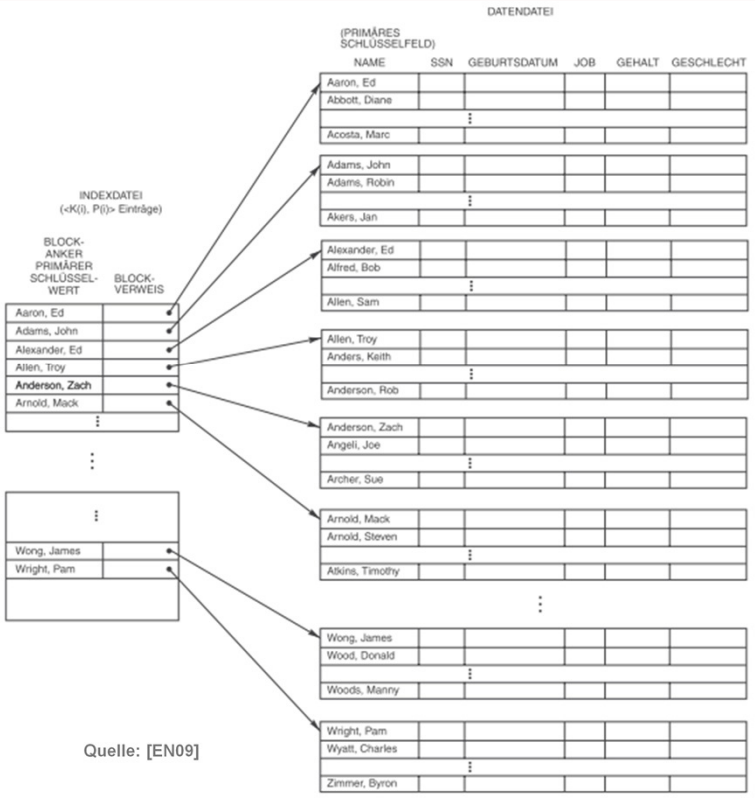

Quelle: [EN09]

Spezielle Indexstrukturen: Baumstrukturen

Abbildung 6.9: Ein Suchbaum der Ordnung p = 3.

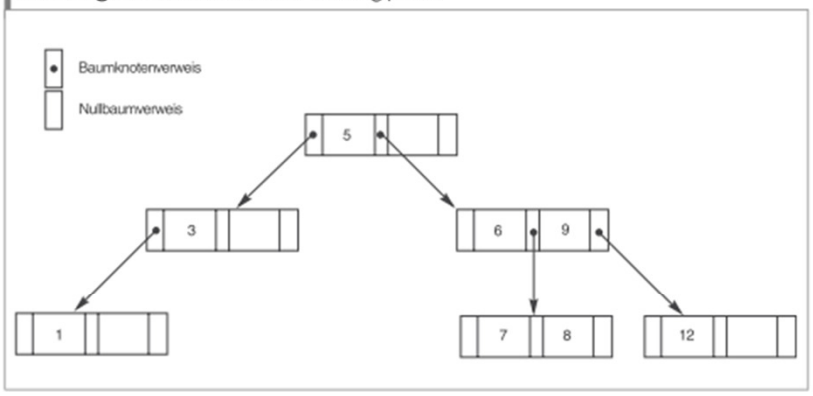

Quelle: [EN09]

- **Bei einfachen Suchbäumen ist abhängig von den Einfüge-, Änderungs-, Löschoperationen ein unausgeglichenes „Wachstum“ möglich.**
- **Lösung hierfür: B-Bäume („balancierte“ Bäume) …**

Die Wahl der primären Dateiorganisation, die Entscheidung zur Erstellung von Indexen, die Wahl der Dateiorganisation der Indexe etc. …

… all dies sind Fragestellungen des physischen Datenbankentwurfs